



DDPM及其在用户建模中的应用

周红 2025/1/3

Outline

一、浅谈扩散模型

二、DDPM背后的数学原理

- Denoising Diffusion Probabilistic Models, [NIPS 2020](#)

三、DDPM在用户建模中的应用

- Diffusion Recommender Model, [SIGIR 2023](#)
- Generate What You Prefer: Reshaping Sequential Recommendation via Guided Diffusion, [NIPS 2023](#)




一、浅谈扩散模型

Forward Process



Reverse Process

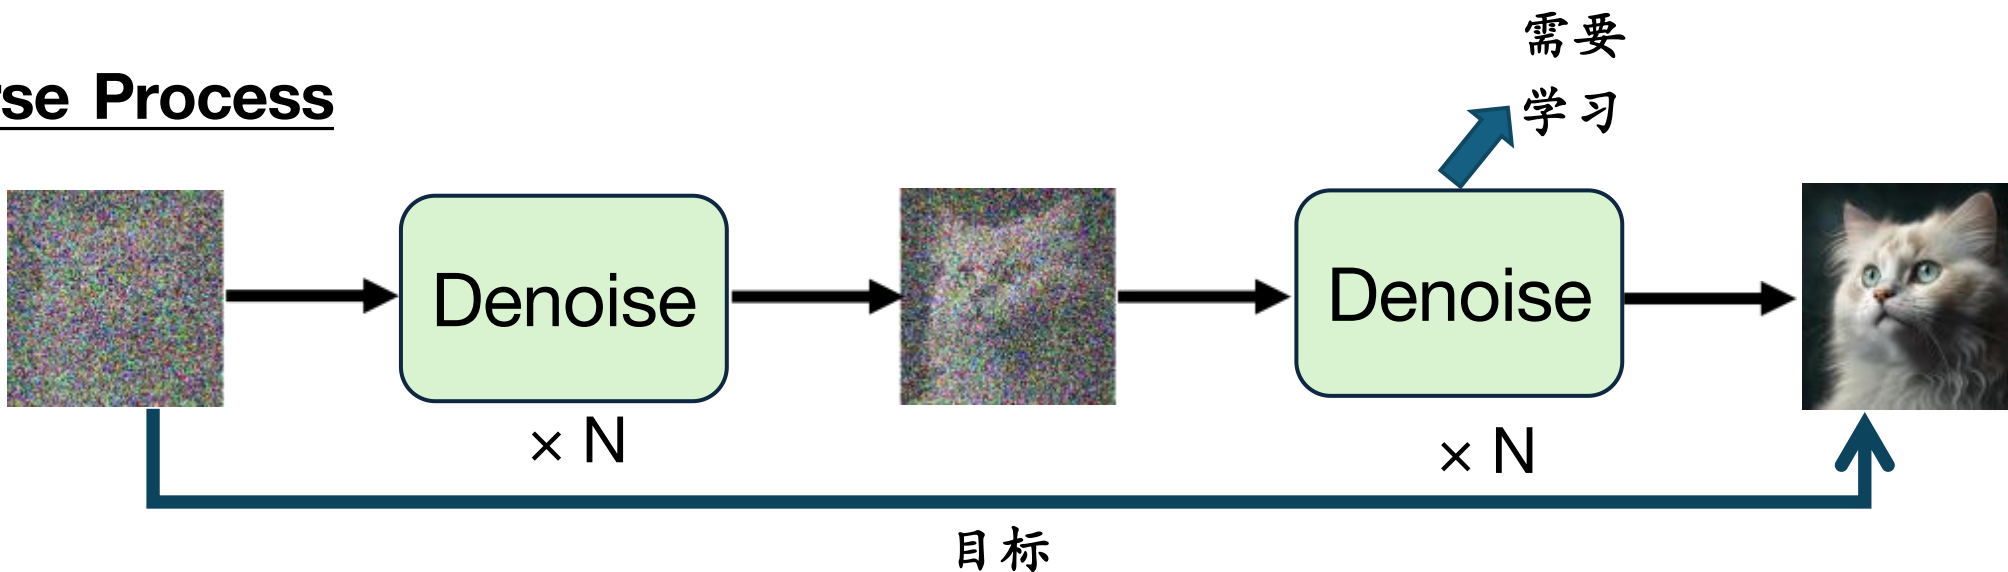


- 目标：从随机噪声中生成符合目标分布的数据。
- 手段：加噪。
- 如何生成：对加噪后的数据进行建模，学习如何通过去噪得到符合目标分布的数据。

Forward Process



Reverse Process





二、DDPM背后的数学原理

Denoising Diffusion Probabilistic Models

Jonathan Ho
UC Berkeley
jonathanho@berkeley.edu

Ajay Jain
UC Berkeley
ajayj@berkeley.edu

Pieter Abbeel
UC Berkeley
pabbeel@cs.berkeley.edu




Figure 2: The directed graphical model considered in this work.

1. Forward Process

- 前向过程是一个初始状态为 \mathbf{x}_0 马尔可夫过程，其中 \mathbf{x}_0 由目标数据集中随机采样得到。
- 不断向分布中添加噪声，该加噪过程是一个高斯分布，均值和方差由 β_t 决定。
- 随着 t 的不断增大，最终数据分布 x_T 变为各向独立的高斯分布。


$$q(\mathbf{x}_{1:T}|\mathbf{x}_0) := \prod_{t=1}^T q(\mathbf{x}_t|\mathbf{x}_{t-1}), \quad q(\mathbf{x}_t|\mathbf{x}_{t-1}) := \mathcal{N}(\mathbf{x}_t; \sqrt{1 - \beta_t}\mathbf{x}_{t-1}, \beta_t\mathbf{I})$$



\mathbf{x}_{t-1}



ϵ



$\sim N(0, I)$

$\xrightarrow{\beta_1, \beta_2, \dots, \beta_T}$
固定值，越来越大

$\sqrt{1 - \beta_t}$



\mathbf{x}_{t-1}

+

β_t



ϵ

=

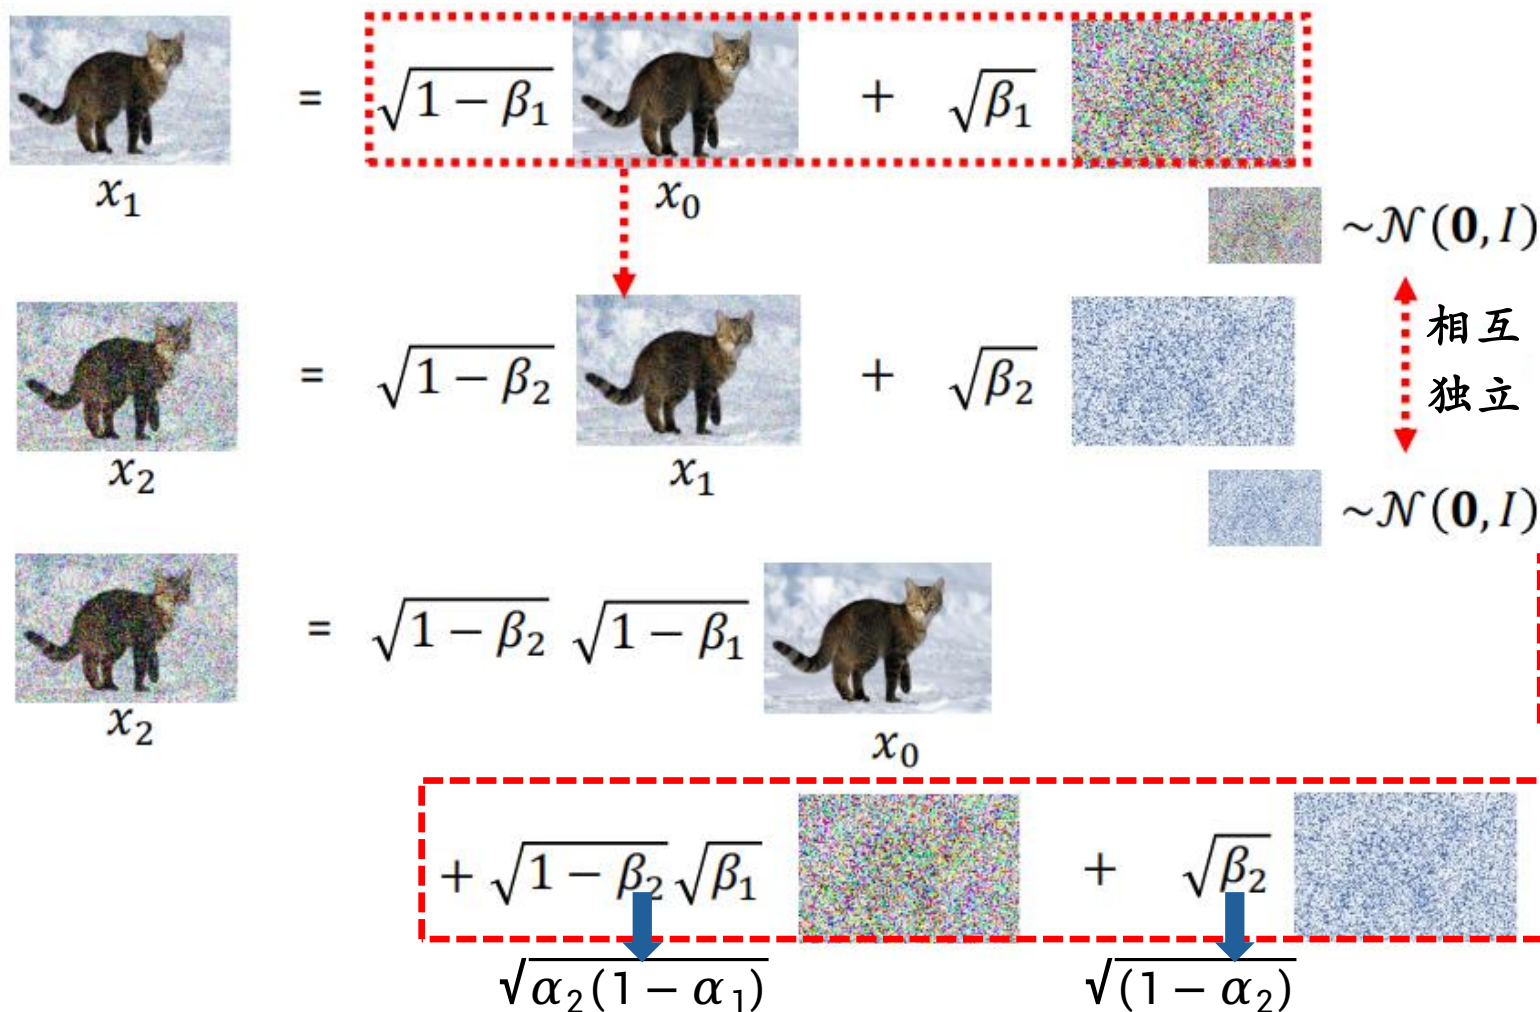


\mathbf{x}_t

1. Forward Process

- 任意时刻的分布可直接得出，不用进行迭代。

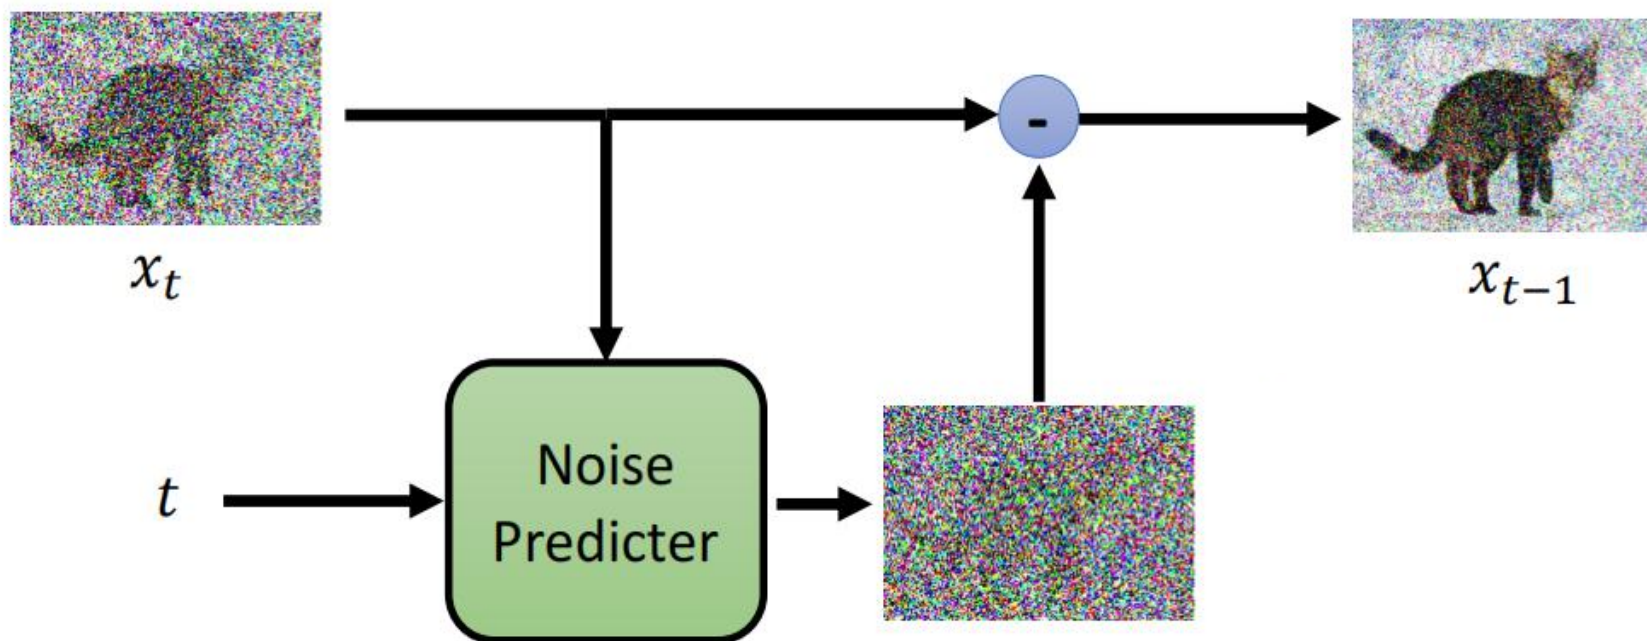
$$q(\mathbf{x}_t|\mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \sqrt{\bar{\alpha}_t}\mathbf{x}_0, (1 - \bar{\alpha}_t)\mathbf{I}) \quad \alpha_t := 1 - \beta_t \text{ and } \bar{\alpha}_t := \prod_{s=1}^t \alpha_s$$



随机变量 \mathbf{X} 和 \mathbf{Y} 服从标准正态分布，且相互独立， $\mathbf{Z}=\mathbf{aX}+\mathbf{bY}$ ，则 $\mathbf{Z} \sim \mathcal{N}(\mathbf{0}, \mathbf{a}^2 + \mathbf{b}^2)$ 。

- 逆向过程是一个初始状态为 \mathbf{x}_T 的马尔可夫过程， \mathbf{x}_T 是服从标准正态分布的高斯噪声。
- 不断从分布中去除噪声，假设该去噪过程也是一个高斯分布，均值和方差取决于模型参数 θ 。
- 随着 t 的不断减小，得到符合目标数据分布的样本。

$$p_{\theta}(\mathbf{x}_{0:T}) := p(\mathbf{x}_T) \prod_{t=1}^T p_{\theta}(\mathbf{x}_{t-1}|\mathbf{x}_t), \quad p_{\theta}(\mathbf{x}_{t-1}|\mathbf{x}_t) := \mathcal{N}(\mathbf{x}_{t-1}; \mu_{\theta}(\mathbf{x}_t, t), \Sigma_{\theta}(\mathbf{x}_t, t))$$

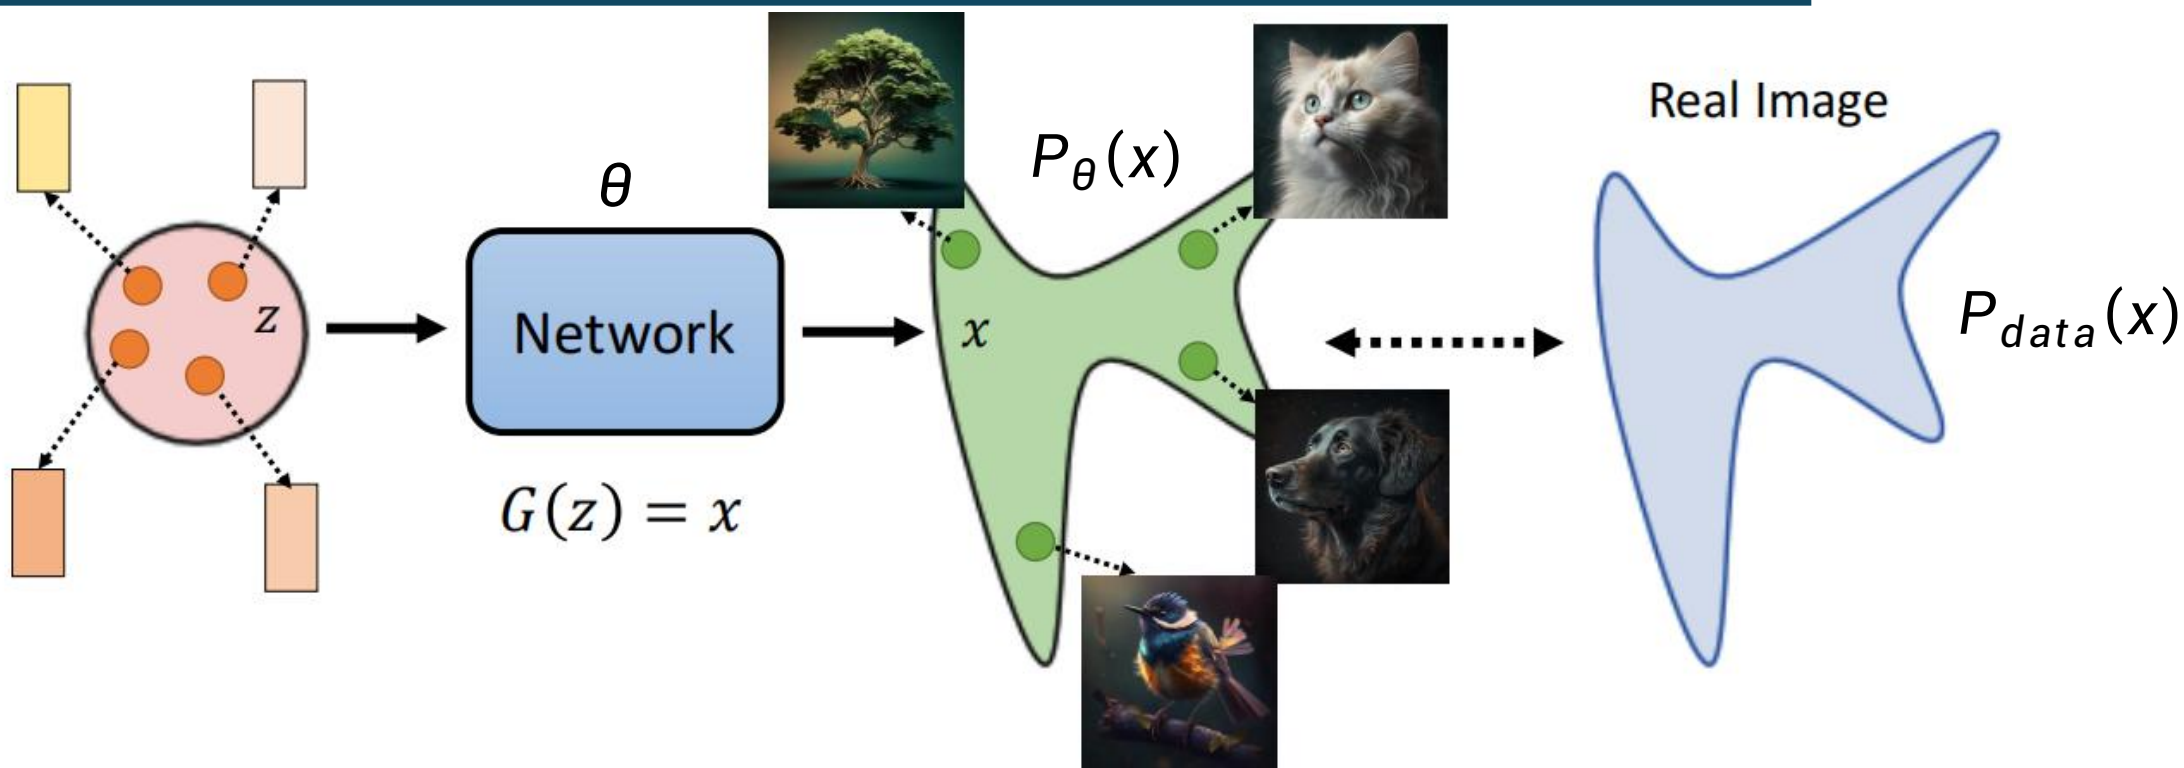


- 图像生成的本质目标：训练得到的模型生成的图像与真实图像是相似的。
- 采用**最大似然估计**，最大化 $P_{\theta}(x_0)$ 。

Sample $\{x^1, x^2, \dots, x^m\}$ from $P_{data}(x)$

We can compute $P_{\theta}(x^i)$

$$\theta^* = \arg \max_{\theta} \prod_{i=1}^m P_{\theta}(x^i)$$




- 最大化对数似然函数的下界

$$\begin{aligned}
 \log p_{\theta}(\mathbf{x}_0) &= \log \int p_{\theta}(\mathbf{x}_{0:T}) d\mathbf{x}_{1:T} \\
 &= \log \int \frac{p_{\theta}(\mathbf{x}_{0:T}) q(\mathbf{x}_{1:T}|\mathbf{x}_0)}{q(\mathbf{x}_{1:T}|\mathbf{x}_0)} d\mathbf{x}_{1:T} \\
 &= \log \mathbb{E}_{q(\mathbf{x}_{1:T}|\mathbf{x}_0)} \left[\frac{p_{\theta}(\mathbf{x}_{0:T})}{q(\mathbf{x}_{1:T}|\mathbf{x}_0)} \right] \\
 &\geq \mathbb{E}_{q(\mathbf{x}_{1:T}|\mathbf{x}_0)} \left[\log \frac{p_{\theta}(\mathbf{x}_{0:T})}{q(\mathbf{x}_{1:T}|\mathbf{x}_0)} \right]
 \end{aligned}$$

期望的定义

根据詹森不等式

对于一个凸函数 f 和一个随机变量 X
 $f(\mathbb{E}[X]) \leq \mathbb{E}[f(X)]$



\mathbf{x}_T

\mathbf{x}_{T-1}

$$p_{\theta}(\mathbf{x}_0) := \int p_{\theta}(\mathbf{x}_{0:T}) d\mathbf{x}_{1:T}$$

$$p_{\theta}(\mathbf{x}_{0:T}) := p(\mathbf{x}_T) \prod_{t=1}^T p_{\theta}(\mathbf{x}_{t-1}|\mathbf{x}_t) \mathbf{x}_0$$

- 最小化负对数似然函数的上界

$$\begin{aligned}
 L &= \mathbb{E}_q \left[-\log \frac{p_\theta(\mathbf{x}_{0:T})}{q(\mathbf{x}_{1:T}|\mathbf{x}_0)} \right] \boxed{p_\theta(\mathbf{x}_{0:T}) := p(\mathbf{x}_T) \prod_{t=1}^T p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)} \\
 &= \mathbb{E}_q \left[-\log p(\mathbf{x}_T) - \sum_{t \geq 1} \log \frac{p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)}{q(\mathbf{x}_t|\mathbf{x}_{t-1})} \right] \text{提出 } t=1 \text{ 的项} \\
 &= \mathbb{E}_q \left[-\log p(\mathbf{x}_T) - \sum_{t > 1} \log \frac{p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)}{q(\mathbf{x}_t|\mathbf{x}_{t-1})} - \log \frac{p_\theta(\mathbf{x}_0|\mathbf{x}_1)}{q(\mathbf{x}_1|\mathbf{x}_0)} \right] \boxed{q(\mathbf{x}_t|\mathbf{x}_{t-1})q(\mathbf{x}_{t-1}|\mathbf{x}_0) = q(\mathbf{x}_t|\mathbf{x}_0)q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)} \\
 &= \mathbb{E}_q \left[-\log p(\mathbf{x}_T) - \sum_{t > 1} \log \frac{p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)}{q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)} \cdot \boxed{\frac{q(\mathbf{x}_{t-1}|\mathbf{x}_0)}{q(\mathbf{x}_t|\mathbf{x}_0)}} - \log \frac{p_\theta(\mathbf{x}_0|\mathbf{x}_1)}{\boxed{q(\mathbf{x}_1|\mathbf{x}_0)}} \right] \text{在 } t > 1 \text{ 的间隔项中消除, 剩两项} \\
 &= \mathbb{E}_q \left[-\log \boxed{\frac{p(\mathbf{x}_T)}{q(\mathbf{x}_T|\mathbf{x}_0)}} - \sum_{t > 1} \log \frac{p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)}{q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)} - \log p_\theta(\mathbf{x}_0|\mathbf{x}_1) \right] \text{① KL散度量两个分布差异} \\
 &= \mathbb{E}_q \left[\text{② } D_{\text{KL}}(q(\mathbf{x}_T|\mathbf{x}_0) \parallel p(\mathbf{x}_T)) + \sum_{t > 1} D_{\text{KL}}(q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) \parallel p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)) - \log p_\theta(\mathbf{x}_0|\mathbf{x}_1) \right]
 \end{aligned}$$

$$\begin{aligned}
 &= \mathbb{E}_{q(\mathbf{x}_{1:T}|\mathbf{x}_0)} [\log p_\theta(\mathbf{x}_0|\mathbf{x}_1)] + \mathbb{E}_{q(\mathbf{x}_{1:T}|\mathbf{x}_0)} \left[\log \frac{p(\mathbf{x}_T)}{q(\mathbf{x}_T|\mathbf{x}_0)} \right] + \sum_{t=2}^T \mathbb{E}_{q(\mathbf{x}_{1:T}|\mathbf{x}_0)} \left[\log \frac{p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)}{q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)} \right] \\
 &= \mathbb{E}_{q(\mathbf{x}_1|\mathbf{x}_0)} [\log p_\theta(\mathbf{x}_0|\mathbf{x}_1)] + \mathbb{E}_{q(\mathbf{x}_T|\mathbf{x}_0)} \left[\log \frac{p(\mathbf{x}_T)}{q(\mathbf{x}_T|\mathbf{x}_0)} \right] + \sum_{t=2}^T \mathbb{E}_{q(\mathbf{x}_t, \mathbf{x}_{t-1}|\mathbf{x}_0)} \left[\log \frac{p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)}{q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)} \right] \\
 &= \underbrace{\mathbb{E}_{q(\mathbf{x}_1|\mathbf{x}_0)} [\log p_\theta(\mathbf{x}_0|\mathbf{x}_1)]}_{\text{reconstruction term}} - \underbrace{D_{\text{KL}}(q(\mathbf{x}_T|\mathbf{x}_0) \parallel p(\mathbf{x}_T))}_{\text{prior matching term}} - \sum_{t=2}^T \underbrace{\mathbb{E}_{q(\mathbf{x}_t|\mathbf{x}_0)} [D_{\text{KL}}(q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) \parallel p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t))]}_{\text{denoising matching term}}
 \end{aligned}$$


$$\mathbb{E}_q \left[\underbrace{D_{\text{KL}}(q(\mathbf{x}_T|\mathbf{x}_0) \parallel p(\mathbf{x}_T))}_{L_T} + \sum_{t>1} \underbrace{D_{\text{KL}}(\underbrace{q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0)}_{L_{t-1}} \parallel \underbrace{p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t)}_{L_0})}_{L_{t-1}} - \log p_\theta(\mathbf{x}_0|\mathbf{x}_1) \right]$$

- L_T : 前向过程确定, $p(\mathbf{x}_T)$ 是标准正态分布, 故为定值。
- L_0 : 可以理解为重构项, 可以用Monte Carlo估计来近似和优化。
- L_{t-1} : 需要重点关注的项。


三项均为已知的高斯分布

$$q(\mathbf{x}_{t-1}|\mathbf{x}_t, \mathbf{x}_0) = \frac{q(\mathbf{x}_{t-1}, \mathbf{x}_t, \mathbf{x}_0)}{q(\mathbf{x}_t, \mathbf{x}_0)} = \frac{q(\mathbf{x}_t|\mathbf{x}_{t-1})q(\mathbf{x}_{t-1}|\mathbf{x}_0)q(\mathbf{x}_0)}{q(\mathbf{x}_t|\mathbf{x}_0)q(\mathbf{x}_0)} = \frac{q(\mathbf{x}_t|\mathbf{x}_{t-1})q(\mathbf{x}_{t-1}|\mathbf{x}_0)}{q(\mathbf{x}_t|\mathbf{x}_0)}$$

$$\propto \mathcal{N}(\mathbf{x}_{t-1}; \underbrace{\frac{\sqrt{\alpha_t}(1-\bar{\alpha}_{t-1})\mathbf{x}_t + \sqrt{\bar{\alpha}_{t-1}}(1-\alpha_t)\mathbf{x}_0}{1-\bar{\alpha}_t}}_{\mu_q(\mathbf{x}_t, \mathbf{x}_0)}, \underbrace{\frac{(1-\alpha_t)(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t}\mathbf{I}}_{\Sigma_q(t)}) \quad p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t) := \mathcal{N}(\mathbf{x}_{t-1}; \mu_\theta(\mathbf{x}_t, t), \Sigma_\theta(\mathbf{x}_t, t))$$



- ①式均值方差固定。
- ②式中作者将方差设为固定值。
- 故两个分布的差异只与均值之差有关; 直观来说, 要想两个分布差异最小, 就需要两分布的均值差异最小。换言之, 需要模型去预测分布①的均值。



$$\tilde{\mu}_t(\mathbf{x}_t, \mathbf{x}_0) := \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1 - \bar{\alpha}_t}\mathbf{x}_0 + \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t}\mathbf{x}_t$$

分布①的均值

$$q(\mathbf{x}_t|\mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \sqrt{\bar{\alpha}_t}\mathbf{x}_0, (1 - \bar{\alpha}_t)\mathbf{I})$$

$$\frac{x_t - \sqrt{1 - \bar{\alpha}_t}\varepsilon}{\sqrt{\bar{\alpha}_t}} = x_0$$

$$\tilde{\mu}_t = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}} \boxed{\varepsilon} \right)$$

- ①式均值方差固定。
- ②式中作者将方差设为固定值。
- 故两个分布的差异只与均值之差有关；直观来说，要想两个分布差异最小，就需要两分布的均差差异最小。换言之，需要模型去预测分布①的均值。

- 在逆向过程中， \mathbf{x}_t 是已知的，故可以只让模型去预测 \mathbf{x}_0 的值。
- 实际中直接预测 \mathbf{x}_0 的值，并将其作为最终生成结果，会导致生成质量较差。
(一步一步来 > 一步到位)

- 对 \mathbf{x}_0 进行转换，式子中只有噪声 ε 是未知的，故最终让模型去预测 ε 的值。

注：以上是直观解释，但均可通过证明得到，具体可参考

Understanding Diffusion Models: A Unified Perspective, arXiv 2022


Algorithm 1 Training

- 1: **repeat**
- 2: $\mathbf{x}_0 \sim q(\mathbf{x}_0)$
- 3: $t \sim \text{Uniform}(\{1, \dots, T\})$
- 4: $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$
- 5: Take gradient descent step on

$$\nabla_{\theta} \left\| \epsilon - \epsilon_{\theta}(\underbrace{\sqrt{\bar{\alpha}_t} \mathbf{x}_0 + \sqrt{1 - \bar{\alpha}_t} \epsilon, t)}_{\text{加噪后的图像}} \right\|^2$$
- 6: **until** converged

目标噪声


预测的噪声



Algorithm 2 Sampling

- 1: $\mathbf{x}_T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$
- 2: **for** $t = T, \dots, 1$ **do**
- 3: $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ if $t > 1$, else $\mathbf{z} = \mathbf{0}$
- 4: $\mathbf{x}_{t-1} = \frac{1}{\sqrt{\alpha_t}} \left(\mathbf{x}_t - \frac{1-\alpha_t}{\sqrt{1-\bar{\alpha}_t}} \underbrace{\epsilon_{\theta}(\mathbf{x}_t, t)}_{\text{噪声预测}} \right) + \sigma_t \mathbf{z}$
- 5: **end for**
- 6: **return** \mathbf{x}_0

$$\tilde{\mu}_t = \frac{1}{\sqrt{\alpha_t}} \left(x_t - \frac{1 - \alpha_t}{\sqrt{1 - \bar{\alpha}_t}} \epsilon \right)$$





三、DDPM在用户建模中的应用

1. 扩散什么？

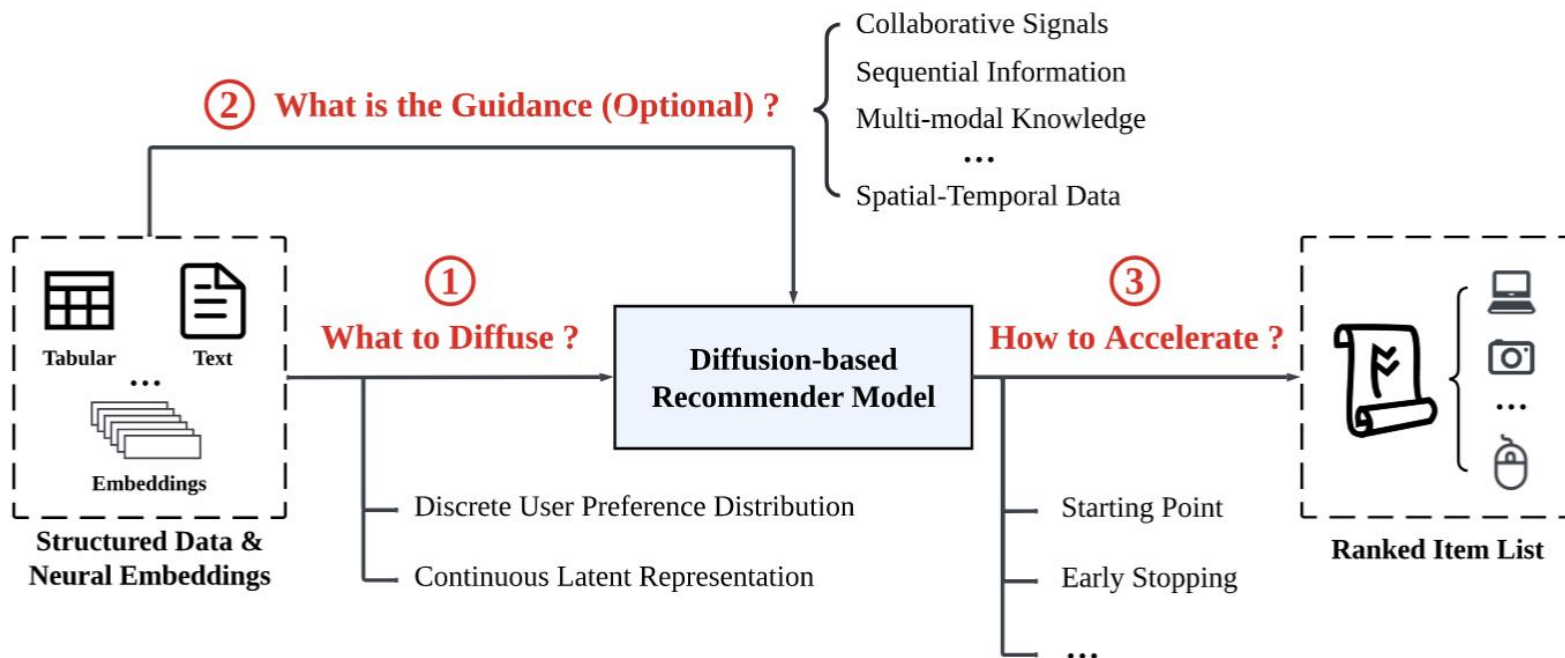
- 在整个项目空间上对**用户-项目交互**进行扩散，例如 $\mathbf{x}_0 = \{\mathbf{0}, \mathbf{1}\}^{|I|}$ 。
- 在连续潜在空间中进行扩散，去噪后的潜在表示通常用作**用户偏好向量**或**目标项目表示**。

2. 用什么来指导？

- 该指导充当条件信息，确保生成的是与每个用户相关的**个性化**推荐。

3. 如何加速？

- 去噪时从有意义的输入（例如加噪后的交互矩阵）开始，而不是传统的纯高斯噪声。



Diffusion Recommender Model

Wenjie Wang

wenjiewang96@gmail.com

National University of Singapore

Yiyan Xu

yiyanxu24@gmail.com

University of Science and Technology
of China

Fuli Feng*

fulifeng93@gmail.com

University of Science and Technology
of China

Xinyu Lin

xylin1028@gmail.com

National University of Singapore

Xiangnan He

xiangnanhe@gmail.com

University of Science and Technology
of China

Tat-Seng Chua

dcscts@nus.edu.sg

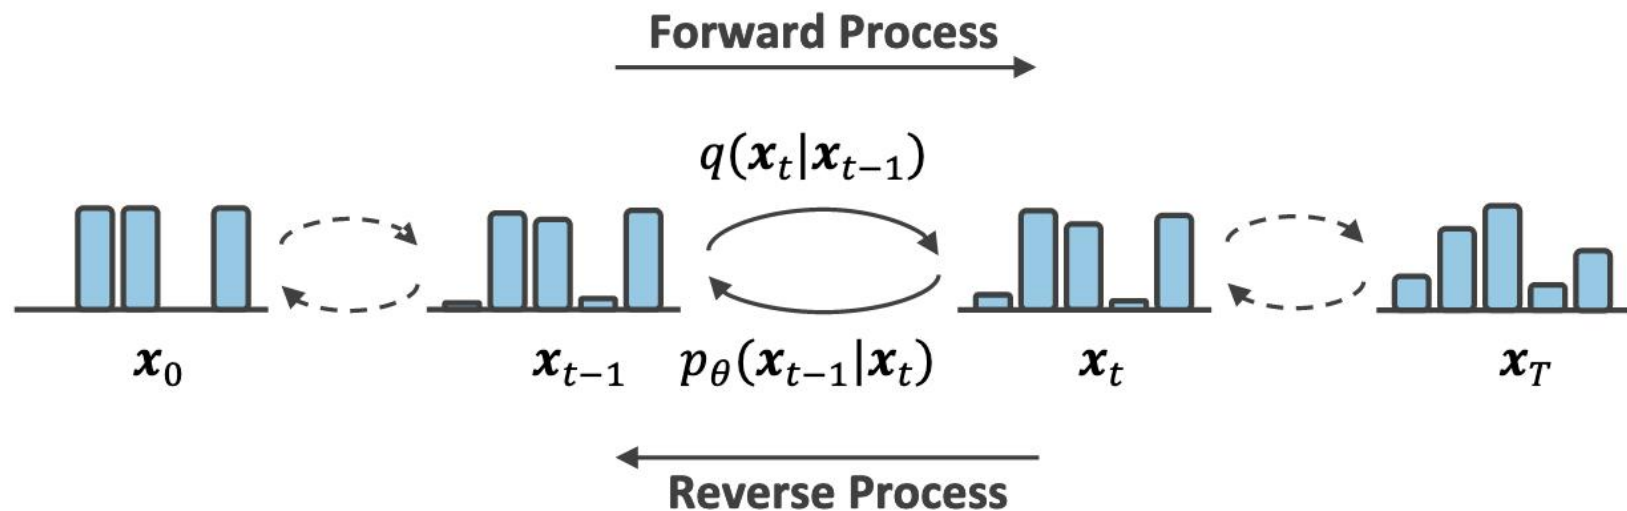
National University of Singapore

论文动机:

- **现有生成模型的局限性:** 变分自编码器 (VAE) 和生成对抗网络 (GAN) 等生成模型常用于模拟用户交互的生成过程, 但它们存在固有缺陷。
 - VAE: 表示能力受限, 可能无法捕捉用户交互的复杂性。
 - GAN: 训练过程不稳定, 难以收敛。
- **扩散模型强大的生成能力。**

扩散什么?

- 给定用户 u , 项目集 I , 交互历史为 $\mathbf{x}_u = \{\mathbf{x}_u^1, \mathbf{x}_u^2, \dots, \mathbf{x}_u^{|I|}\}$, \mathbf{x}_u^i 为 1 表示用户 u 与项目 i 进行了交互, 为 0 则表示没有交互。设 $\mathbf{x}_0 = \mathbf{x}_u$ 为初始状态。



个性化信息保留&加速

- 首先对 \mathbf{x}_0 进行加噪, 变为 $\mathbf{x}_{T'}$, 然后设置 $\hat{\mathbf{x}}_T = \mathbf{x}_{T'}$, 并以 $\hat{\mathbf{x}}_T$ 为输入 (即不是从传统的纯高斯噪声开始) 来执行反向去噪操作。

• 训练过程

Algorithm 1 DiffRec Training

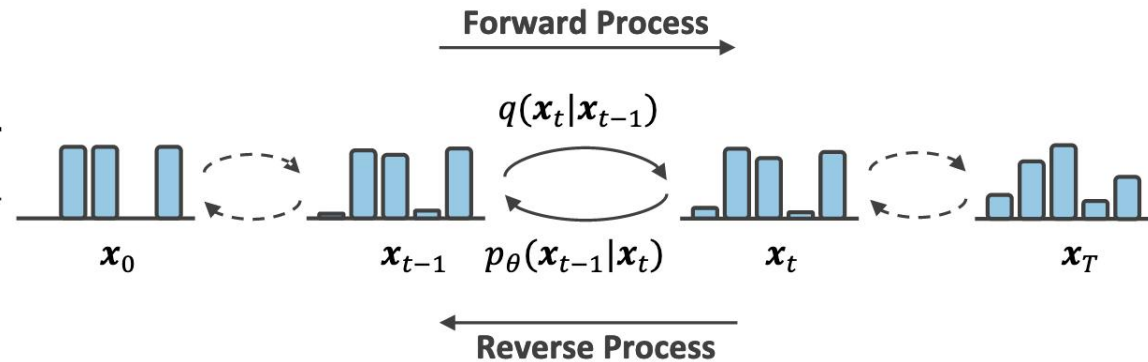
Input: all users' interactions \bar{X} and randomly initialized θ .

- 1: **repeat**
- 2: Sample a batch of users' interactions $X \subset \bar{X}$.
- 3: **for all** $x_0 \in X$ **do**
- 4: Sample $t \sim \mathcal{U}(1, T)$ or $t \sim p_t$, $\epsilon \sim \mathcal{N}(0, I)$;
- 5: Compute x_t given x_0 , t , and ϵ via $q(x_t|x_0)$ in Eq. (3);
- 6: Compute \mathcal{L}_t by Eq. (11) if $t > 1$, otherwise by Eq. (12);
- 7: Take gradient descent step on $\nabla_{\theta} \mathcal{L}_t$ to optimize θ ;

8: **until** converged

Output: optimized θ .

对原始交互进行加噪



$$q(x_t|x_0) = \mathcal{N}(x_t; \sqrt{\bar{\alpha}_t}x_0, (1 - \bar{\alpha}_t)I), \quad (3)$$

$$\mathcal{L}_t = \mathbb{E}_{q(x_t|x_0)} \left[\frac{1}{2} \left(\frac{\bar{\alpha}_{t-1}}{1 - \bar{\alpha}_{t-1}} - \frac{\bar{\alpha}_t}{1 - \bar{\alpha}_t} \right) \|\hat{x}_{\theta}(x_t, t) - x_0\|_2^2 \right], \quad (11)$$

$$\begin{aligned} \mathcal{L}_1 &\triangleq -\mathbb{E}_{q(x_1|x_0)} [\log p_{\theta}(x_0|x_1)] \\ &= \mathbb{E}_{q(x_1|x_0)} [\|\hat{x}_{\theta}(x_1, 1) - x_0\|_2^2], \end{aligned} \quad (12)$$

训练参数为 θ 的模型，模型根据加噪后的交互和时间步来对 x_0 进行预测

推理过程

Algorithm 2 DiffRec Inference

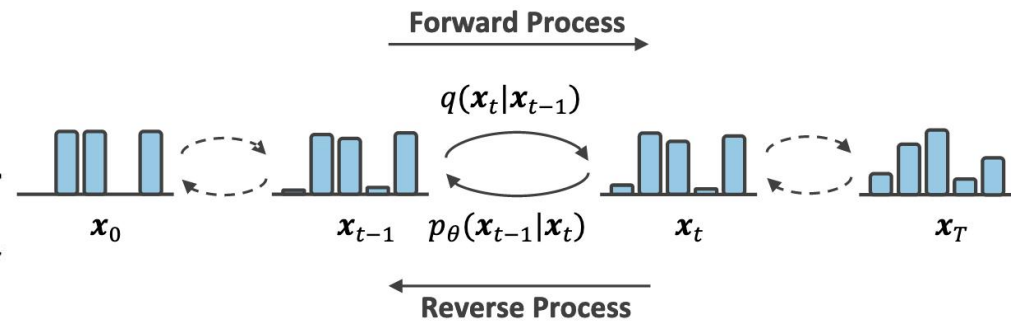
Input: θ and the interaction history \mathbf{x}_0 of user u .

- 1: Sample $\epsilon \sim \mathcal{N}(\mathbf{0}, I)$.
- 2: Compute $\mathbf{x}_{T'}$ given \mathbf{x}_0 , T' , and ϵ via Eq. (3), and set $\hat{\mathbf{x}}_T = \mathbf{x}_{T'}$.
- 3: **for** $t = T, \dots, 1$ **do**
- 4: $\hat{\mathbf{x}}_{t-1} = \mu_\theta(\hat{\mathbf{x}}_t, t)$ calculated from $\hat{\mathbf{x}}_t$ and $\hat{\mathbf{x}}_\theta(\cdot)$ via Eq. (10);

Output: the interaction probabilities $\hat{\mathbf{x}}_0$ for user u .

$$p_\theta(\mathbf{x}_{t-1}|\mathbf{x}_t) := \mathcal{N}(\mathbf{x}_{t-1}; \mu_\theta(\mathbf{x}_t, t), \Sigma_\theta(\mathbf{x}_t, t))$$

使用对原始交互加噪后的样本作为去噪时的输入



$$q(\mathbf{x}_t|\mathbf{x}_0) = \mathcal{N}(\mathbf{x}_t; \sqrt{\bar{\alpha}_t}\mathbf{x}_0, (1 - \bar{\alpha}_t)I), \quad (3)$$

$$\mu_\theta(\mathbf{x}_t, t) = \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t}\mathbf{x}_t + \frac{\sqrt{\bar{\alpha}_{t-1}}(1 - \alpha_t)}{1 - \bar{\alpha}_t}\hat{\mathbf{x}}_\theta(\mathbf{x}_t, t) \quad (10)$$

对 \mathbf{x}_0 进行预测

$$\tilde{\mu}_t(\mathbf{x}_t, \mathbf{x}_0) := \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1 - \bar{\alpha}_t}\mathbf{x}_0 + \frac{\sqrt{\alpha_t}(1 - \bar{\alpha}_{t-1})}{1 - \bar{\alpha}_t}\mathbf{x}_t$$

Generate What You Prefer: Reshaping Sequential Recommendation via Guided Diffusion

Zhengyi Yang[‡] Jiancan Wu^{‡*} Zhicai Wang[‡] Yancheng Yuan^{§*} Xiang Wang^{‡†} Xiangnan He^{‡†}

[‡]University of Science and Technology of China

[§]The Hong Kong Polytechnic University

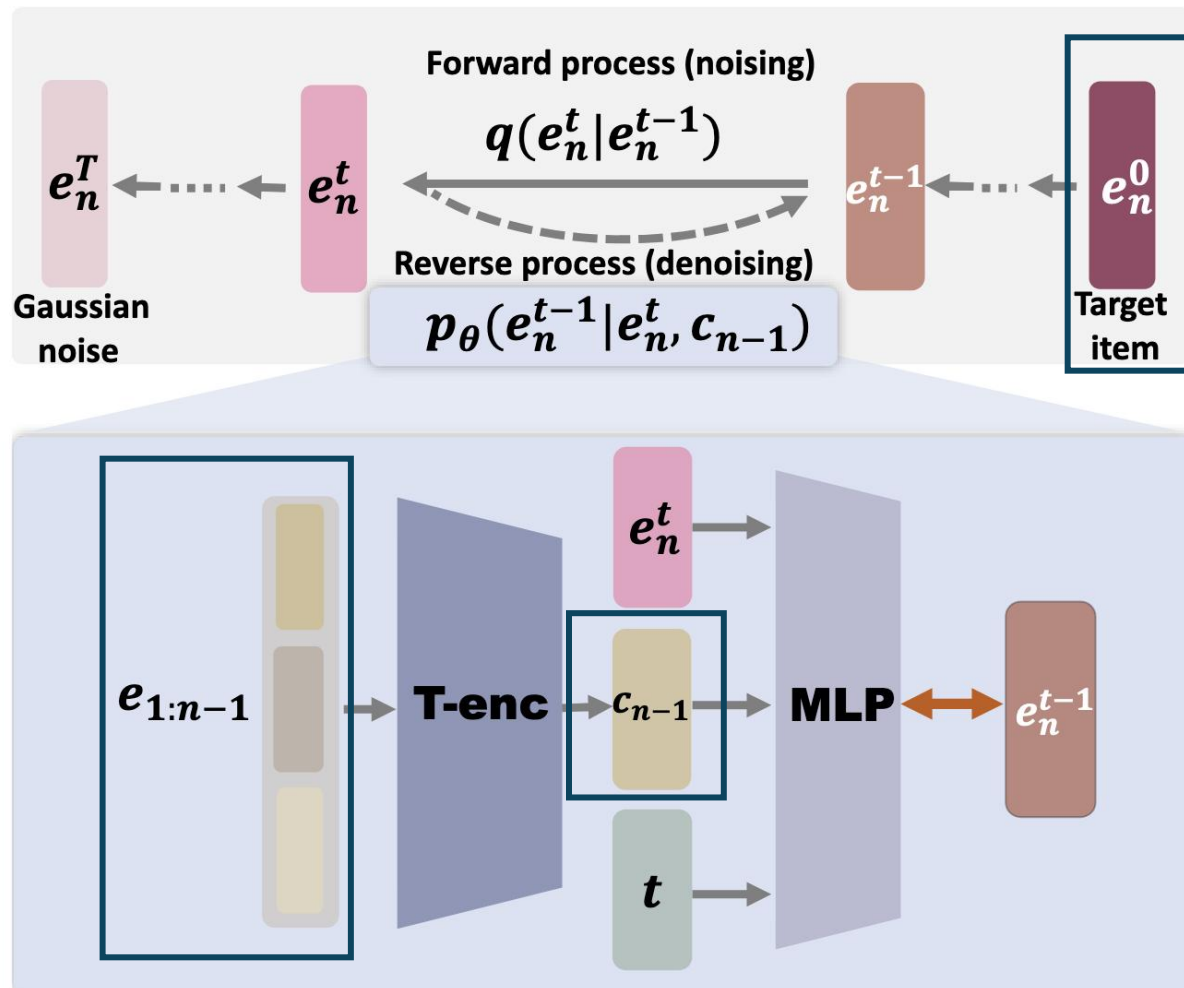
{yangzhy, wangzhic}@mail.ustc.edu.cn

{wujcan, xiangwang1223, xiangnanhe}@gmail.com

yancheng.yuan@polyu.edu.hk

论文动机：解决当前序列推荐系统中的两大局限性。

- 与人类行为的差异：传统的序列推荐模型采用“学习分类”的范式，通过负采样添加负例，训练模型区分用户是否偏好某项物品。而人类在选择时，往往会在脑海中**构想出理想的物品**，然后寻找与之匹配的选项。
- 负采样的局限性：可能引入噪声，削弱对用户真实偏好的学习效果。



扩散什么？

- 通常，每个项目 $v \in I$ 最初被转换为其相应的嵌入向量 e 。因此交互序列可以表示为 $e_{1:n-1} = [e_1, e_2, \dots, e_{n-1}]$ ，使用扩散模型来生成用户可能选择的 **下一个项目** e_n^0 。

用什么来指导？

- 需要解决个性化问题，提出用相应的 **历史交互序列** 来指导去噪过程。
- 用户在进行购买时，倾向于在他们的头脑中创建一个理想化的项目，而这个项目的生成与用户交互历史是高度相关的。

Algorithm 1 Training phase of DreamRec

1: **repeat**

2: $\mathbf{e}_n^0, \mathbf{e}_{1:n-1} \sim \mathcal{D}$

3: $\mathbf{c}_{n-1} = \text{T-enc}(\mathbf{e}_{1:n-1})$

4: With probability p_u : $\mathbf{c}_{n-1} = \Phi$

5: $t \sim \text{Uniform}(\{1, \dots, T\})$

6: $\epsilon \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$

7: $\mathbf{e}_n^t = \sqrt{\bar{\alpha}_t} \mathbf{e}_n^0 + \sqrt{1 - \bar{\alpha}_t} \epsilon$

8: $\theta = \theta - \mu \nabla_{\theta} \|\mathbf{e}_n^0 - \boxed{f_{\theta}(\mathbf{e}_n^t, \mathbf{c}_{n-1}, t)}\|^2$

9: **until** converged

▷ Sample and embed a data from training set.

▷ Encode interaction sequence.

▷ Perform unconditional training with probability p_u .

▷ Sample diffusion step.

▷ Sample Gaussian noise.

▷ Corrupt the target item with Gaussian noise.

▷ Take gradient descent step, μ is the step size.



- 同时训练无条件去噪扩散模型 $f_{\theta}(\mathbf{e}_n^t, t)$ 和利用历史交互作为条件的条件去噪扩散模型 $f_{\theta}(\mathbf{e}_n^t, \mathbf{c}_{n-1}, t)$
- 有条件和无条件的权衡——个性化和多样化推荐的权衡

Algorithm 2 Generation phase of DreamRec

```

1:  $\mathbf{e}_{1:n-1} \sim \mathcal{D}_t$ 
2:  $\mathbf{e}_n^T \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$ 
3:  $\mathbf{c}_{n-1} = \text{T-enc}(\mathbf{e}_{1:n-1})$ 
4: for  $t = T, \dots, 1$  do
5:    $\mathbf{z} \sim \mathcal{N}(\mathbf{0}, \mathbf{I})$  if  $t > 1$ , else  $\mathbf{z} = \mathbf{0}$ 
6:    $\tilde{f}_\theta(\mathbf{e}_n^t, \mathbf{c}_{n-1}, t) = (1 + w) f_\theta(\mathbf{e}_n^t, \mathbf{c}_{n-1}, t) - w f_\theta(\mathbf{e}_n^t, \Phi, t)$ 
7:    $\mathbf{e}_n^{t-1} = \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1-\bar{\alpha}_t} \tilde{f}_\theta(\mathbf{e}_n^t, \mathbf{c}_{n-1}, t) + \frac{\sqrt{\alpha_t}(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t} \mathbf{e}_n^t + \sqrt{\tilde{\beta}_t} \mathbf{z}$ 
8: end for
9: return  $\mathbf{e}_n^0$ 
  
```

- ▷ Sample and embed a data from testing set.
- ▷ Sample Gaussian noise.
- ▷ Encode interaction sequence.
- ▷ Denoise for T steps.
- ▷ Sample denoising variance.
- ▷ Control the strength of guidance.
- ▷ Denoise for one step.

$$\tilde{\mu}_t(\mathbf{x}_t, \mathbf{x}_0) := \frac{\sqrt{\bar{\alpha}_{t-1}}\beta_t}{1-\bar{\alpha}_t} \mathbf{x}_0 + \frac{\sqrt{\alpha_t}(1-\bar{\alpha}_{t-1})}{1-\bar{\alpha}_t} \mathbf{x}_t$$

- 相应地，在推理阶段也需要进行有条件和无条件的权衡。
- w 是控制 \mathbf{c}_{n-1} 强度的超参数，较高的 w 值可以增强个性化指导，但可能会破坏扩散的泛化能力，从而降低生成的目标项的质量。



中国科学院信息工程研究所
INSTITUTE OF INFORMATION ENGINEERING, CAS



Thanks